

학생 수학 성적(G3) 영향 변수 분석

중간 진행 보고서

작성일	2026년 5월
데이터셋	UCI Student Performance Dataset (student-mat.csv)
분석 단계	EDA → 전처리 → 모델 비교 → 변수 선정 → 심층 분석 (완료)
잔여 기간	약 1개월
상태	중간 보고 — 핵심 분석 완료, 추가 심층·정리 단계 진행 예정

1. 프로젝트 목표

본 프로젝트는 포르투갈 중·고등학생의 수학 최종 성적(G3, 0~20점)에 실질적으로 영향을 미치는 변수를 규명하는 것을 목표로 한다. 분석의 초점은 예측 정확도 극대화가 아닌, 학업 성취에 관여하는 핵심 요인의 방향성과 상대적 중요도를 데이터 기반으로 해석하는 데 있다.

1-1. 세부 목표

- 랜덤포레스트 변수 중요도와 상관계수 분석을 통해 G3에 유의미한 영향을 미치는 핵심 변수를 선정
- 통계 검정(ANOVA, Kruskal-Wallis)으로 개별 변수의 유의성을 검증하고 불필요한 변수를 제거
- 낙제(G3=0) 학생과 일반 학생의 특성 차이를 파악하여 모델의 한계와 가능성을 탐색
- 최종적으로 회귀·분류 모델을 통해 학업 성취 패턴을 예측 가능한 형태로 정리

1-2. 목표 부합 여부 점검

현 시점에서 세부 목표 1~3은 분석이 완료되었으며, 목표 4(분류 모델)는 기초 결과를 확보한 상태이다. 전반적으로 프로젝트는 설정된 목표에 부합하여 진행되고 있다.

세부 목표	달성 여부	비고
핵심 변수 선정	✅ 완료	8개 유효 변수 확정
통계 유의성 검증	✅ 완료	health/freetime 제외 근거 확보
낙제 학생 특성 분석	✅ 완료	별도 모델로 R ² 개선 확인
회귀·분류 모델 정리	🔄 진행중	기본 결과 확보, 해석·개선 필요

2. 사용 데이터

2-1. 데이터셋 개요

항목	내용
출처	UCI Machine Learning Repository — Student Performance Dataset
파일명	student-mat.csv (수학 과목)
원본 크기	395행 × 33열
분석 크기	395행 × 29열 (G1·G2·school·address 4개 컬럼 제거 후)
결측값	없음 (모든 컬럼 결측 0개)
종속변수	G3 (수학 최종 성적, 0~20점 / 평균 10.4점 / 중앙값 11점)

2-2. 컬럼 제거 근거

- G1, G2 (1·2차 중간 성적): 포함 시 G3을 거의 직접 결정하여 다른 변수의 독립적 기여를 가림
- school: 학교 구분 정보로 분석 목적(학생 개인 요인)과 무관
- address: 거주지 유형으로 분석 목적과 무관

2-3. 변수 구성

유형	대표 변수	설명
수치형(17개)	age, failures, absences, studytime, Medu, Fedu, goout, health, freetime 등	나이, 낙제 횟수, 결석 수, 공부 시간, 부모 교육수준, 외출·여가·건강 지수 등 정수 값

범주형(12개)	sex, Mjob, Fjob, reason, guardian, famrel 등	성별, 부모 직업군, 학교 선택 이유, 보호자 유형, 가족 관계 등 문자열 값 (Label Encoding 적용)
종속변수	G3	수학 최종 성적 0~20점 / 낙제(G3=0) 학생 38명(9.6%) 별도 구간 형성

3. 지금까지의 분석 진행 현황

분석은 총 13개 섹션으로 구성되며, 현재 모든 섹션의 코드 및 1차 해석이 완성된 상태이다. 아래 표는 단계별 내용과 주요 발견 사항을 정리한 것이다.

단 계	내용	주요 발견	상태
1	환경 설정 및 데이터 로드	395×29 확보, 4개 컬럼 제거 완료	✓ 완료
2	탐색적 데이터 분석(EDA)	G3 평균 10.4, 낙제 9.6%, failures·Medu가 G3와 강한 상관	✓ 완료
3	데이터 전처리 및 모델 비교	Label Encoding, 선형·KNN·RF 3모델 비교 → RF 우수 판정	✓ 완료
4	RF 변수 중요도 분석	absences 1위(19.6%), failures 2위(14.2%), RF와 상관계수 교차 확인	✓ 완료
5	Top 10 변수 심층 분석	failures: 0→3 증가 시 G3 중앙값 11→6점 급락 / absences 불규칙 패턴 발견	✓ 완료
6	absences 극단값 처리	IQR 기준 상한 20회, 15명(3.8%) 극단값 / 구간화(3단) 방식이 추세 파악에 유효	✓ 완료
7	health·freetime 유의성 검정	ANOVA/Kruskal 모두 $p>0.05$ → 단독 유의 효과 없음 확인	✓ 완료
8	최종 유효 변수 8개 확정	health·freetime 제외, 8개 변수 확정 / 전체·축소 모델 성능 비교(R^2 0.326→0.198)	✓ 완료

9	최종 결론 요약	8개 변수 방향·강도 통합 정리, failures 단독 최강 예측 변수 확인	✓ 완료
10	absences 심층 분석	failures와 조합 시 설명력 발휘 → RF 중요도 1위의 원인 규명	✓ 완료
11	낙제 학생 별도 처리	낙제 제외 시 R ² 개선, 낙제 학생은 일반 변수로 설명 어려움 확인	✓ 완료
12	하이퍼파라미터 튜닝	RandomizedSearchCV 40회 탐색, 최적 파라미터 도출	✓ 완료
13	이진 분류 모델	낙제 여부·우수 학생 분류 / AUC 수치 확보 (해석 보완 필요)	↺ 해석 보완

4. 주요 중간 결과

4-1. 최종 유효 변수 8개

랜덤포레스트 변수 중요도와 피어슨 상관계수, 통계 검정을 종합하여 최종 유효 변수 8개를 확정하였다.

변수	영향 방향	RF 중요도	상관계수(r)	핵심 해석
failures	음(-)	14.2%	-0.360	낙제 횟수 증가 시 G3 급락. 가장 신뢰할 수 있는 단일 변수
absences	복합	19.6%	+0.034	단독 선형 효과 미미. failures와 조합 시 설명력 증가 (RF 1위 이유)
goout	음(-)	5.2%	-0.133	외출 빈도 높을수록 G3 소폭 하락
age	음(-)	4.4%	-0.162	나이 많을수록 G3 낮음. failures와 연동된 간접 효과 가능성
Mjob	양(+)	3.8%	+0.102	어머니 직업군에 따라 G3 차이 존재 (health 직군 최고)
studytime	양(+)	3.5%	+0.098	공부 시간 길수록 G3 완만히 상승. freetime보다 실질 기여 큼
Fjob	양(+)	3.5%	+0.042	아버지 직업군에 따라 G3 차이 존재
Fedu	양(+)	3.0%	+0.152	아버지 교육수준 높을수록 G3 상승 경향

4-2. 모델 성능 비교 현황

모델	R ²	RMSE	MAE	비고
RF 전체 변수 (28개)	0.326	3.718	—	기준 모델
RF 유효 변수 (8개)	0.198	4.055	—	해석용 모델
RF 낙제 학생 제외	↑ 개선	↓ 감소	—	낙제 제외 후 향상
RF 하이퍼파라미터 튜닝 후	0.326+	↓ 소폭	↓ 소폭	RandomizedSearchCV
이진 분류 - 낙제 여부 (RF/GB)	AUC 확보	—	—	해석 보완 필요
이진 분류 - 우수 학생 (RF/GB)	AUC 확보	—	—	해석 보완 필요

4-3. 제외된 변수 및 근거

변수	ANOVA p값	Kruskal p값	제외 근거
health	0.211	0.147	두 검정 모두 $p>0.05$. failures 통제 시 독립 효과 없음 (교차 분석 확인)
freetime	0.066	0.059	두 검정 모두 $p>0.05$. studytime 통제 시 독립 효과 없음 (교차 분석 확인)

5. 향후 1개월 진행 계획

잔여 기간(약 4주)을 3단계로 구성하여 분석 심화, 결과 정리, 보고서 완성 순서로 진행한다.

주차	기간	핵심 과제	산출물
1주차	5월 3~4주	① 이진 분류 결과 해석 보완 (AUC·Confusion Matrix 심층 해석)② 분류 결과와 회귀 결과 연계 서술③ 모델별 오분류 사례 검토	분류 분석 완성본
2주차	6월 1주	① 변수 간 상호작용 추가 탐색 (예: $age \times failures$ 조합)② 낙제 학생 프로파일링 심화 (어떤 변수가 낙제를	심층 분석 노트북

		더 잘 예측하는가?)③ 필요 시 Feature Engineering 시도	
3주차	6월 2주	① 전체 분석 흐름 재점검 및 스토리라인 정리② 시각화 품질 개선 (제목·레이블·색상 일관성)③ 핵심 인사이트 3~5개 압축 서술 작성	정리된 노트북 v2
4주차	6월 3주	① 최종 보고서 작성 (서론·방법·결과·결론)② 발표 자료 준비 (핵심 그래프 5~7개 선정)③ 동료 검토 및 피드백 반영	최종 보고서·발표자료

5-1. 1주차 세부 과제: 이진 분류 보완

- 낙제 분류 모델의 Precision-Recall Trade-off 분석: 낙제 학생 조기 발견이 목적이라면 Recall을 우선하는 임계값 조정 필요
- 우수 학생 분류 모델의 False Negative(우수인데 일반으로 분류) 사례의 공통 특성 탐색
- 3개 모델(Logistic, RF, GB)의 특성 비교 서술: 선형 vs 비선형 경계의 차이를 시각화로 보완

5-2. 2주차 세부 과제: 심층 분석 확장

- age × failures 교호작용: 나이가 많을수록 낙제 횟수도 많은 경향이 성적에 중첩적으로 어떤 영향을 주는지 히트맵으로 시각화
- 낙제 학생(G3=0) 프로파일: 낙제 학생에서 특징적으로 높은 변수(예: goout, absences)와 낮은 변수(studytime, Fedu) 비교 분석
- 선택적 Feature Engineering: absences 구간화 변수(낮음/중간/높음)를 모델에 포함했을 때 R^2 변화 확인

5-3. 3~4주차 세부 과제: 정리 및 완성

- 전체 스토리라인: '어떤 변수가 학생 성적에 영향을 주는가?' → '그 영향의 방향과 크기는?' → '예측이 가능한가?' → '어떤 학생이 위험군인가?' 순서로 서술
- 핵심 시각화 5~7개 선정 기준: ① failures vs G3 박스플롯, ② RF 중요도+상관계수 통합 차트, ③ absences 조합 히트맵, ④ ROC Curve 비교, ⑤ 잔차 분포
- 최종 보고서 구성: 서론(배경·목표) → 데이터 설명 → 방법론 → 변수 분석 결과 → 모델 결과 → 결론·한계·후속 연구 제안

6. 현재 한계 및 보완 방향

현재 한계	보완 방향
회귀 $R^2=0.198\sim0.326$ 으로 설명력 제한적	본 분석 목적이 '해석'임을 명확히 서술. G1·G2 제외한 의의 강조
낙제 학생 과대 예측 문제 (잔차 분포 치우침)	이진 분류 모델을 통한 낙제 판별로 보완. 회귀+분류 이중 구조 명시
absences 단독 선형 효과 부재 ($r\approx0$)	RF 중요도와의 괴리를 '조합 효과'로 설명하는 섹션 이미 작성됨. 최종 보고서에 강조
이진 분류 AUC 해석 미완성	1주차 우선 과제로 지정. Precision-Recall 분석 및 임계값 조정 포함
변수 간 교호작용 분석 부족	2주차에 $age\times failures$, $absences\times failures$ 조합 분석 추가 예정
표본 크기($n=395$)로 인한 일부 셀 불안정	소수 셀($n<10$)에 대한 해석 주의 경고 문구 추가. 구간화로 셀 집계

7. 프로젝트 목표 부합 종합 점검

아래 항목별로 현재 분석이 당초 프로젝트 목표와 얼마나 부합하는지를 점검한다.

【목표 부합 체크리스트】

- ✓ 데이터 기반 핵심 변수 규명 — RF 중요도·상관계수·통계 검정 3중 확인으로 8개 변수 확정
- ✓ 통계적 근거 제시 — ANOVA·Kruskal-Wallis로 제외 변수(health, freetime) 근거 명확히 제시
- ✓ 낙제 학생 특성 탐색 — 별도 모델 구축 및 잔차 분석으로 낙제 구간의 특수성 확인
- ✓ 예측 가능성 탐색 — 회귀·분류 양면 접근으로 G3 예측 및 그룹 판별 가능성 확인
- ↻ 분류 모델 해석 심화 — AUC 해석 및 실용적 임계값 설정 작업 남음
- ↻ 최종 보고서 완성 — 스토리라인 정리·시각화 개선·동료 검토 남음

전반적으로 분석의 핵심 목표는 충실히 달성되었으며, 잔여 1개월은 결과의 완성도를 높이고 최종 보고서와 발표 자료를 완성하는 데 집중할 예정이다. 프로젝트의 방향성은 당초 설정과 일치하고 있으며, 추가 분석을 통해 더욱 견고한 결론을 도출할 수 있을 것으로 판단된다.

이 중간 보고서는 진행 현황 공유 및 추후 일정 계획을 위해 작성되었습니다.